

허리둘레와 공복혈당 간의 관계

1. INTRODUCTION

식전혈당(공복혈당)은 최소 8시간 이상 금식 후 측정한 혈중 포도당 농도로, 당뇨병 예방 및 대사 건강 관리에 있어 중요한 지표이다.

일반적으로 수치가 100~125 mg/dL 이상일 경우 공복혈당장애(전당뇨) 상태로 분류되며, 조기 관리가 가능한 가역적 상태로 알려져 있다. 허리둘레는 내장지방 축적 정도를 반영하는 대표적인 신체지표로, 인슐린 저항성과 혈당 조절 기능과 밀접한 관련이 있다.

이에 본 보고서는 국가중점 개방데이터(건강검진정보)를 활용하여 허리둘레와 공복혈당 간의 관계를 분석하고, 당뇨 예방을 위한 기초적 근거를 제시하고자 한다.

2. DATA

본 분석에서는 국가중점 개방데이터에서 제공하는 2022년 건강검진정보 데이터를 활용하였다. 해당 데이터는 총 약 100만 개의 행(row)과 30개의 열(column)로 구성되어 있다. 대규모 데이터로 인한 개인 분석 환경의 연산 자원 한계를 고려하여, 전체 데이터 중 10만 개의 샘플을 무작위 표본추출 방식으로 선별하여 분석에 사용하였다.

데이터의 각 행은 개인 단위의 건강검진 기록을 의미하여, 주요 변수는 다음과 같

다. 기준년도, 가입자일련번호, 성별코드, 연령대코드(5세단위), 시도코드, 신장(5cm 단위), 체중(5kg단위), 허리둘레, 시력(좌), 시력(우), 청력(좌), 청력(우), 수축기혈압, 이완기혈압, 식전혈당(공복혈당), 총콜레스테롤, 트리글리세라이드, HDL콜레스테롤, LDL콜레스테롤, 혈색소, 요단백, 혈청크레아티닌, 혈청지오티(AST), 혈청지피티(ALT), 감마지티피, 흡연상태, 음주여부, 구강검진수검여부, 치아우식증유무, 치석 등으로 구성되어 있다.

3. DATA PREPROCESSING & EDA

3.1 결측치 처리

본 데이터셋에는 다수의 결측치가 존재하며, 변수별 결측 비율은 최소 10% 미만부터 최대 50% 이상까지 다양하게 분포되어 있다. 이에 따라 결측치 처리 전략을 결측 비율 기준으로 차등 적용하였다.

결측 비율이 10% 미만인 변수의 경우, 해당 데이터 행을 제거하더라도 전체 데이터 분포에 미치는 영향이 크지 않을 것으로 판단하여 listwise deletion 방식을 적용하였다.

반면, 결측 비율이 50% 이상인 변수에 대해서는 단순 삭제 시 정보 손실이 크고, 변수 간 상관관계를 고려하지 않는 비합리적인 선택이 될 수 있다고 판단하여 결측치 대체(imputation) 방식을 적용하였다.

해당 변수들은 ‘총콜레스테롤’, ‘트리글리세라이드’, ‘HDL콜레스테롤’, ‘LDL콜레스테롤’, ‘치아우식증유무’, ‘치석’이다.

결측치 패턴 분석 결과, ‘총콜레스테롤’, ‘트리글리세라이드’, ‘HDL콜레스테롤’, ‘LDL콜레스테롤’ 네 변수는 공통 결측치가 65,518개, 비공통 결측치가 687개로 매우 높은 동시 결측 구조를 보였다. 또한 ‘치아우식증유무’와 ‘치석’의 변수는 65,561개 결측치가 모두 공통 결측 형태로 나타났다. 이러한 결측 구조는 변수 그룹 간 강한 연관성(latent correlation structure)이 존재할 가능성을 시사하며, 일부 변수만 선택적으로 삭제하는 경우 중요한 관계 정보가 소실될 수 있다고 판단하였다.

이에 따라 혈액검사 관련 변수 그룹(‘총콜레스테롤’, ‘트리글리세라이드’, ‘HDL콜레스테롤’, ‘LDL콜레스테롤’)에 대해서는 KNN Imputer를 활용한 결측치 대체를 수행하였다. Imputation 과정에서는 임상적/의학적인 연관성을 고려하여 다음 변수들을 함께 사용하였다. ‘체중(5kg단위)’, ‘허리둘레’, ‘수축기혈압’, ‘이완기혈압’, ‘식전혈당(공복혈당)’, ‘혈색소’, ‘요단백’, ‘혈청크레아티닌’, ‘혈청지오티(AST)’, ‘혈청지피티(ALT)’, ‘감마지티피’.

반면, ‘치아우식증유무’와 ‘치석’의 경우 구강검진 영역에 속하는 변수로서 혈당 및 대사 지표와의 직접적인 생리적 연관성이 낮다고 판단하였으며, 별도의 독립 분석 목적이 아닌 본 연구 목적(공복혈당 중심 분석)에 비추어 전체 분석 변수 집합에서 제거하였다.

3.2 Feature Selection

분석 목적에 부합하지 않거나 정보적 의미

가 낮은 변수들에 대해 Feature Selection을 수행하였다.

‘기준년도’ 변수는 모든 관측치가 2022년이라는 단일 값을 가지므로 정보 변별력이 없다고 판단하여 제거하였다. ‘가입자일련번호’ 변수는 단순 식별자(identifier) 역할을 수행하는 변수로, 수치적 의미나 통계적 해석 가능성이 없으므로 분석 변수에서 제외하였다.

또한 ‘시도코드’, ‘청력(좌)’, ‘청력(우)’, ‘구강검진수검여부’ 변수들은 본 연구의 핵심 타겟 변수인 식전혈당(공복혈당)과의 직접적인 생리적/의학적인 연관성이 낮다고 판단하여 분석 변수 집합에서 제거하였다.

이를 통해 모델 해석 가능성과 분석 구조의 단순성을 동시에 확보하고자 하였다.

3.3 Outlier Detection

이상치 탐지는 일반적으로 IQR(Interquartile Range) 기반의 통계적 방법을 통해 수행할 수 있으나, 건강/의학 데이터의 특성상 극단값(extreme value)이 반드시 오류값이 아닌 임상적으로 유의미한 실제 관측치일 가능성이 존재한다. 이에 따라 본 연구에서는 단순한 통계적 기준에 따른 이상치 제거는 수행하지 않았으며, 의미론적(semantic) 기준에 기반한 이상치 제거 전략을 적용하였다.

구체적으로 허리둘레 값이 600을 초과하는 관측치는 생리적으로 불가능한 수치로 판단하여 이상치로 정의하고 제거하였다. 또한 식전혈당(공복혈당) 값이 649로 기록된 관측치는 임상적으로 비현실적인 수치이며 측정 오류 또는 입력 오류 가능성이 높다고 판단하여, 상한값을 300으로 설정

하고 300 이상 값을 가지는 관측치를 제거하였다.

이는 통계적 분포 기반 이상치 제거가 아닌 의학적 타당성에 기반한 의미론적 이상치 제거 방식이다.

3.4 Distribution Visualization

본 데이터셋은 연속형 변수와 범주형 변수를 동시에 포함하고 있다. 이에 따라 연속형 변수들을 대상으로 scatter plot 및 분포 시각화를 수행하여 데이터 분포 구조를 분석하였다.

시각화 결과, ‘허리둘레’, ‘수축기혈압’, ‘이완기혈압’, ‘혈색소’를 제외한 대부분의 연속형 변수들의 분포가 Right-Skewed distribution 형태를 보이는 것을 확인하였다.




Figure 1. 시각화 한 분포 중 일부 이미지이다. 혈색소를 제외한 나머지 세 변수가 Right-Skew한 형태임을 확인할 수 있다.

이와 같은 비대칭 분포를 그대로 사용할 경우, 회귀계수 추정의 안정성 저하, 분산 불균형, 극단값 영향 확대 등의 문제가 발생할 수 있어 모델링 과정에서 구조적 왜곡이 발생할 가능성이 있다. 따라서 Right-Skew 형태를 가지는 변수들을 대상으로 Log transformation을 적용하여 분포의 비

대칭성을 완화하였다..




Figure 2. 로그 변환을 수행한 후 데이터의 scatter plot으로 형태가 보정되었음을 확인할 수 있다.

3.5 Robust Scaling

연속형 변수들 간 값의 스케일 범위가 상이하고 분포 폭이 크게 차이남에 따라, 표준화 과정에서 이상치에 민감하지 않은 스케일링 방법의 사용이 요구되었다. 이에 따라 본 연구에서는 중앙값과 사분위 범위를 기준으로 하는 RobustScaler를 적용하였다.

RobustScaler는 극단값의 영향을 최소화하면서 변수 간 스케일 차이를 보정할 수 있어, 이상치가 존재하는 건강 데이터 구조에 보다 적합한 스케일링 방식일 것으로 판단하였다.

3.6 Correlation




Figure 3. 연속형 변수들을 활용하여 상관관계 히트맵을 생성한 이미지이다.

식전혈당(공복혈당)과 연속형 변수들 간의 상관관계 분석 결과, 허리둘레와 식전혈당 간의 상관계수는 0.25로 비교적 약한 양의 상관관계를 보였다. 가장 높은 상관성을 보인 변수는 트리글리세라이드로, 식전혈당과의 상관계수는 0.29로 나타났다.

전체적으로 모든 변수들이 식전혈당(공복혈당)과 약한 수준의 선형 상관관계를 가지는 것으로 확인되었으며, 이는 혈당이 단일 요인에 의해 결정되기보다는 복합적 생리 요인들의 상호작용 결과임을 시사한다.

한편, 단일 변수와 식전혈당(공복혈당) 간의 상관성은 약한 반면, 변수 간 상관성이 높은 변수 쌍들이 다수 존재함을 확인하였다. 이는 다중공선성으로 가능성을 시사하는 구조이나, VIF(Variance Inflation Factor) 분석 결과 유의 수준의 공선성은 확인되지 않아 변수 제거는 수행하지 않았다.

3.7 Chi-Square Analysis

범주형 변수와 식전혈당(공복혈당) 간의 관계성을 분석하기 위해 카이제곱 검정을 수행하였다.

이를 위해 식전혈당(공복혈당) 변수를 범주형 변수로 변환한 새로운 컬럼 'FBG_cat'을 생성하였다. 해당 변수는 대한당뇨학회 기준에 따라 다음과 같이 구간화하였다.

- 100 미만 : 정상(0)
- 100~125 : 공복혈당장애(전당뇨)(1)
- 125 이상 : 당뇨(2)로 구간화 하였다.

이 구간화 변수를 기반으로 범주형 변수들과 식전혈당 범주 간의 독립성 검정을 수행하여 통계적 연관성을 분석하였다.

<성별>

FBG_cat	0	1	2
성별			
1	27554	18559	5172
2	32007	12754	2742

chi2=2013.38, p-value=0.0000, dof=2

- p-value < 0.05이고 검정통계량 값이 충분히 크기 때문에 유의미한 변수라고 판단할 수 있다.

- 정상군의 비율은 여성(67.4%), 남성(53.7%)로 여성이 정상 혈당 유지 비율이 높다.

- 전당뇨 비율의 경우 남성이 약 9.3% 더 높았으며 당뇨 유병 비율은 남성이 여성의 거의 2배 수준이다.

<흡연상태>

FBG_cat	0	1	2
흡연상태			
1	40894	18294	4130
2	8354	6408	1760
3	10313	6611	2024

chi2=1528.67, p-value=0.0000, dof=4

- 흡연상태 변수도 p-value < 0.05로 유의미한 변수이다.

- 과거에 흡연을 했었거나 현재 흡연을 할 경우 비흡연자에 비해 전당뇨, 당뇨 비율이 훨씬 높다.

- 이는 흡연이 혈당 대사 시스템을 직접적으로 교란하는 변수가 맞음을 나타낸다.

<음주여부>

FBG_cat	0	1	2
음주여부			
0	19648	10925	3215
1	39913	20388	4699

chi2=190.63, p-value=0.0000, dof=2

- p-value < 0.05로 음주여부는 유의미한 변수이다.

- 음주를 할 경우 전당뇨와 당뇨의 절대수가 더 높게 나타나고 고혈당군 비중이

크다.

<연령대코드(5세 단위)>

FBG_cat	0	1	1
연령대코드 (5세단위)			
5	3033	426	32
6	5895	1074	63
7	6792	1861	181
8	5265	1981	276
9	7741	3415	614
10	5894	3163	710
11	7162	4422	1109
12	4817	3760	1089
13	5412	4383	1418
14	3050	2568	865
15	2494	2291	841
16	986	1022	367
17	807	726	296
18	213	221	53

chi2=7712.16, p-value=0.0000, dof=26

- p-value < 0.05로 연령대코드(5세 단위)는 유의미한 변수이다.

- 연령대가 증가할수록 정상 비율은 줄고 전당뇨 및 당뇨 비율이 증가한다.
- 9~13 구간 이후부터 당뇨 비율이 급격하게 증가한다.

<요단백>

FBG_cat	0	1	2
요단백			
1	55138	28736	6683
2	2849	1449	513
3	1223	815	443
4	250	229	183
5	77	70	72
6	24	14	20

chi2=1071.46, p-value=0.0000, dof=10

- p-value < 0.05로 요단백은 유의미한 변수이다.

- 요단백의 단계가 증가할 수록 정상 비율은 줄고 전당뇨와 당뇨 비율이 증가하는 것을 확인할 수 있다.
- 특히 고단백뇨 단계에서 당뇨의 비중이

급증한다.

4. MODELING

4.1 LinearRegression

여러 변수를 포함한 다중 회귀 모델을 적합하기에 앞서, 단일 회귀 모델을 통해 허리둘레가 종속변수인 식전혈당(공복혈당)을 어느 정도 설명할 수 있는지를 먼저 분석하였다.

OLS Regression Results						
=====						
Dep. Variable:	식전혈당 (공복혈당)		R-squared:	0.063		
Model:	OLS		Adj. R-squared:	0.063		
Method:	Least Squares		F-statistic:	6635.		
Date:	Wed, 11 Feb 2026		Prob (F-statistic):	0.00		
Time:	10:28:47		Log-Likelihood:	-4.4615e+05		
No. Observations:	98788		AIC:	8.923e+05		
Df Residuals:	98786		BIC:	8.923e+05		
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	100.7240	0.071	1428.688	0.000	100.586	100.862
허리둘레	7.5987	0.093	81.458	0.000	7.416	7.782
=====						
Omnibus:	79222.626		Durbin-Watson:	2.008		
Prob(Omnibus):	0.000		Jarque-Bera (JB):	2322428.417		
Skew:	3.711		Prob(JB):	0.00		
Kurtosis:	25.564		Cond. No.	1.33		

Figure 4. '허리둘레'만 독립변수로 넣은 OLS Regression Result

- 허리둘레가 1단위 증가할 때 식전혈당이 7.5987 만큼 증가한다.
- 허리둘레의 p-value = 0.0000 < 0.05이므로 허리둘레는 통계적으로 유의미한 변수라고 할 수 있다. 즉, 허리둘레가 증가할 때 식전혈당(공복혈당) 증가하는 것은 우연이 아니다.
- 허리둘레의 신뢰구간은 [0.025, 0.975]로 허리둘레가 혈당에 미치는 영향이 95% 신뢰수준에서 해당 구간 사이에 있을 것이라 할 수 있다.
- 해당 모델의 설명력을 나타내는 값인 R-squared 값이 0.063으로 허리둘레가 식전혈당(공복혈당)의 값을 약 6%만 설명할 수 있다.
- 식전혈당(공복혈당)이 유의미한 변수이긴 하나 허리둘레만으로 식전혈당(공복혈당)을 설명하기엔 부족하다.

결론적으로, 모델의 설명력을 향상시키기 위해 추가적인 설명 변수가 필요함을 파악하였다.

4.2 OLS Forward Selection (Using AIC)

본 연구에서는 AIC 값을 기준으로 설명력이 높은 변수를 하나씩 추가하는 Forward Selection 기반 다중 회귀 모델링 기법을 적용하였다.

OLS Regression Results						
Dep. Variable:	식전혈당_공복혈당		R-squared:	0.172		
Model:	OLS		Adj. R-squared:	0.172		
Method:	Least Squares		F-statistic:	1142.		
Date:	Wed, 11 Feb 2026		Prob (F-statistic):	0.00		
Time:	10:30:02		Log-Likelihood:	-4.4002e+05		
No. Observations:	98788		AIC:	8.801e+05		
Df Residuals:	98769		BIC:	8.803e+05		
Df Model:	18					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	80.3014	0.335	239.534	0.000	79.644	80.958
C(성별)[T.2]	2.2408	0.228	9.844	0.000	1.795	2.687
C(흡연상태)[T.2.0]	0.4403	0.209	2.109	0.035	0.031	0.850
C(흡연상태)[T.3.0]	0.5640	0.203	2.776	0.006	0.166	0.962
트리글리세라이드	4.3561	0.171	25.420	0.000	4.020	4.692
연령대코드_5세단위	1.3621	0.025	54.561	0.000	1.313	1.411
총콜레스테롤	1.1317	0.280	4.042	0.000	0.583	1.680
감마지티피	2.7500	0.122	22.629	0.000	2.512	2.988
요단백	3.6492	0.136	26.806	0.000	3.382	3.916
허리둘레	1.6512	0.122	13.551	0.000	1.412	1.890
LDL콜레스테롤	-3.7794	0.237	-15.939	0.000	-4.244	-3.315
혈청지오티_AST	-2.6105	0.128	-20.328	0.000	-2.862	-2.359
혈청지피티_ALT	2.4542	0.154	15.975	0.000	2.153	2.755
수축기혈압	1.0308	0.097	10.658	0.000	0.841	1.220
HDL콜레스테롤	-1.4031	0.172	-8.165	0.000	-1.740	-1.066
혈색소	1.2694	0.127	10.010	0.000	1.021	1.518
시력_우	-0.2714	0.066	-4.123	0.000	-0.400	-0.142
시력_좌	-0.1916	0.063	-3.054	0.002	-0.315	-0.069
혈청크레아티닌	0.1940	0.112	1.737	0.082	-0.025	0.413
Omnibus:	78550.877	Durbin-Watson:	2.007			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	2531899.729			
Skew:	3.621	Prob(JB):	0.00			
Kurtosis:	26.721	Cond. No.	68.7			

Figure 5. AIC 기반 전진 선택법으로 다중회귀모델 적합한 결과

- 해당 모델의 R-squared = 0.172로 모델은 식전혈당(공복혈당) 값을 약 17.2% 정도 설명할 수 있다.
- 해당 모델에 포함된 변수들은 '트리글리세라이드', '연령대코드_5세단위', '총콜레스테롤', '감마지티피', '요단백', '허리둘레', 'LDL콜레스테롤', '혈청지오티_AST', '혈청지피티_ALT', '수축기혈압', 'HDL콜레스테롤', '성별', '혈색소', '시력_우', '시력_좌', '흡연상태', '혈청크레아티닌'이다.
- F-statistic = 1142, Prob(F) = 0.00으로 독립 변수 집합이 통계적으로 유의하게 종속변수를 설명한다.
- '트리글리세라이드', '요단백', '감마지티피',

'혈청지피티(ALT)', '허리둘레', '연령대코드(5세단위)', '수축기혈압', '혈색소' 컬럼들은 혈당 증가의 요인으로 식전혈당(공복혈당)과 양의 선형관계를 가진다.

- 'LDL콜레스테롤', 'HDL콜레스테롤', '혈청지오티(AST)', '시력(좌)', '시력(우)' 컬럼들은 식전혈당(공복혈당)과 음의 선형관계를 가진다.

5. CONCLUSION

본 연구는 허리둘레와 식전혈당(공복혈당) 간의 관계를 분석해보았다. 분석 결과, 허리둘레와 식전혈당 간에는 통계적으로 유의미한 양(+)의 관계가 존재하며, 허리둘레가 증가할 수록 식전혈당 수치 또한 증가하는 경향을 보였다.

그러나 허리둘레 단일 변수만으로는 공복혈당 수치의 변동성을 충분히 설명하기에는 한계가 있음을 확인하였다.

따라서 다양한 생리학적 지표를 포함하여 공복혈당 수치에 직접적인 영향을 미치는 요인을 분석하였다. 분석 결과, 트리글리세라이드와 요단백이 식전혈당 수치와 특히 높은 관련성을 가지는 것으로 나타났다.

이들 변수를 포함하여 약 18개의 설명 변수 집합으로 다중 회귀 모델을 적합한 결과, 해당 모델은 식전혈당(공복혈당) 값 변동의 약 17.2% 설명하는 것으로 분석되었다.

이는 식전혈당(공복혈당)이 구조적으로 단일 변수 모델로는 설명되기 어려운 복합적 특성을 지닌 변수이며, 생리학적 요인 외에도 유전적 요인, 식습관, 운동 습관, 스트레스, 호르몬 변화 등과 같은 다양한 외생 변수들의 영향을 크게 받는 변수임을 시사한다.